

Otimização Contínua

Relatório da Atividade — AV2

Elyson Caique Alves Brito — 583231

Metodologia

Foram implementados o **Gradiente Descendente** (passo constante, condição de Armijo e backtracking) e o **Método de Newton**, ambos combinados com as estratégias de passo citadas. O critério de parada adotado em todos os experimentos foi

$$\|\nabla f(x_k)\| \leq 10^{-6},$$

ou um número máximo de **1000 iterações**. Para cada experimento são reportados o número de iterações, o valor final da função, a norma do gradiente final, o número de avaliações de f , ∇f e H , além dos gráficos de convergência e, para as funções bidimensionais, das curvas de nível com as trajetórias correspondentes.

1 Problema 1: $f(x, y) = 1000x^2 + y^2$

a) Gradiente e Hessiana

O gradiente de f é

$$\nabla f(x, y) = \begin{pmatrix} 2000x \\ 2y \end{pmatrix},$$

e a Hessiana, constante (pois f é quadrática), é

$$Hf(x, y) = \begin{pmatrix} 2000 & 0 \\ 0 & 2 \end{pmatrix}.$$

Os autovalores de H são $\lambda_{\min} = 2$ e $\lambda_{\max} = 2000$, resultando em

$$\kappa(H) = \frac{\lambda_{\max}}{\lambda_{\min}} = 1000,$$

um valor elevado que torna a função **mal condicionada**. O mínimo global é $x^* = (0, 0)$, com $f(x^*) = 0$.

b)/c) Implementação e resultados

A Tabela 1 apresenta os resultados de todas as estratégias, partindo de $x_0 = (1, 1)^T$.

Table 1: Problema 1 — todos os métodos, $x_0 = (1, 1)^T$.

Método	Iter.	f^*	$\ \nabla f\ $	Aval. f	Aval. ∇f	Aval. H
GD Passo Constante	1000	$1,83 \times 10^1$	$2,70 \times 10^2$	2001	2001	0
GD Armijo	1000	$1,75 \times 10^{-2}$	$8,06 \times 10^{-1}$	11965	2001	0
GD Backtracking	1000	$1,85 \times 10^{-2}$	$7,00 \times 10^{-1}$	32973	2001	0
Newton (qualquer passo)	1	0	0	3	4	1

Nenhuma das estratégias de gradiente descendente converge dentro do limite de 1000 iterações — comportamento esperado, dado o elevado condicionamento ($\kappa = 1000$). O método de Newton, por outro lado, resolve o problema exatamente em **1 iteração**, pois sua direção é obtida resolvendo o sistema $Hd = -\nabla f$ de forma exata, independentemente do condicionamento de H .




Figure 1: Trajetórias de todos os métodos sobrepostas às curvas de nível.




Figure 2: Convergência de $f(x_k)$ e $\|\nabla f(x_k)\|$: Gradiente Descendente vs. Newton.

e) Efeito do condicionamento da Hessiana

Para investigar esse efeito, testou-se a família $f_\kappa(x, y) = \kappa x^2 + y^2$ com GD+Armijo, cuja taxa de convergência teórica é $q = \frac{\kappa-1}{\kappa+1}$. A Tabela 2 resume os resultados.

Table 2: Iterações necessárias para convergência em função de $\kappa(H)$.

$\kappa(H)$	1	5	10	50	100	500 e 1000
Iterações	1	33	60	333	667	não convergem (limite de 1000)

O número de iterações cresce aproximadamente de forma linear com κ , confirmando a previsão teórica: quanto maior o condicionamento, mais lenta a convergência do gradiente descendente.




Figure 3: Número de iterações necessárias e taxa de convergência teórica q em função de κ .

d)/f) Comparação final

Em média, o gradiente descendente precisou de aproximadamente **1000 vezes mais iterações** que o método de Newton para este problema, ilustrando o forte impacto do uso de informação de segunda ordem em problemas quadráticos bem definidos.

2 Problema 2: $f(x, y) = (x + 2y - 7)^2 + (2x + y - 5)^2$

a) Gradiente e Hessiana

O gradiente é

$$\nabla f(x, y) = \begin{pmatrix} 10x + 8y - 34 \\ 8x + 10y - 38 \end{pmatrix},$$

e a Hessiana, também constante, é

$$Hf(x, y) = \begin{pmatrix} 10 & 8 \\ 8 & 10 \end{pmatrix}.$$

Os autovalores são $\lambda_{\min} = 2$ e $\lambda_{\max} = 18$, dando $\kappa(H) = 9$ — um valor bem mais moderado que no Problema 1, caracterizando uma função **bem condicionada**. O mínimo global é $x^* = (1, 3)$, com $f(x^*) = 0$.

b)/c) Implementação e resultados

Partindo de $x_0 = (0, 0)^T$, com $f(x_0) = 74,0$ e $\|\nabla f(x_0)\| = 51,0$, todos os métodos convergiram corretamente ao mínimo global. A Tabela 3 apresenta os resultados completos, incluindo o Backtracking.

Table 3: Problema 2 — comparação de métodos, $x_0 = (0, 0)^T$.

Método	Iter.	f^*	$\ \nabla f\ $	Aval. f	Aval. ∇f	Aval. H
GD Passo Constante	80	$2,31 \times 10^{-14}$	$9,01 \times 10^{-7}$	161	162	0
GD Armijo	39	$8,17 \times 10^{-14}$	$6,57 \times 10^{-7}$	198	80	0
GD Backtracking	255	$2,72 \times 10^{-14}$	$9,89 \times 10^{-7}$	3061	512	0
Newton + Armijo	1	0	0	3	4	1

d) Comparação do número de iterações

Com $\kappa = 9$ (baixo), todas as estratégias de gradiente descendente convergem confortavelmente dentro do limite de 1000 iterações. O Armijo foi a estratégia mais eficiente em número de iterações (39), seguida do passo constante (80) e do backtracking (255), que exigiu muito mais avaliações de função por ser mais conservador na escolha do passo. O método de Newton, como esperado para um problema quadrático, resolveu em uma única iteração.




Figure 4: Trajetórias de todos os métodos sobrepostas às curvas de nível.




Figure 5: Comparação em barras: número de iterações e avaliações de f e ∇f .

3 Problema 3: Função de Beale

Considere

$$f(x, y) = (1,5 - x + xy)^2 + (2,25 - x + xy^2)^2 + (2,625 - x + xy^3)^2,$$

uma função não-quadrática e não-convexa, com mínimo global em $x^* = (3, 0,5)$, $f(x^*) = 0$.

a) Gradiente e Hessiana

Diferente dos Problemas 1 e 2, a Hessiana **não é constante**. As expressões analíticas foram validadas numericamente por diferenças finitas, com erro máximo da ordem de 10^{-3} a 10^{-10} . A avaliação em diferentes pontos revela mudanças de convexidade local: em $x_0 = (1, 1)$, os autovalores são $\{-9,83, 78,33\}$ — Hessiana **indefinida**; já em $x^* = (3, 0,5)$, os autovalores são $\{0,30, 48,98\}$, com $\kappa(H) \approx 162,5$ — Hessiana definida positiva.

b)/c) Implementação e resultados

A partir de $x_0 = (1, 1)^T$, obtiveram-se os resultados da Tabela 4.

Table 4: Problema 3 — resultados em $x_0 = (1, 1)^T$.

Método	Iter.	f^*	$\ \nabla f\ $	x_{final}
GD + Armijo	786	$8,46 \times 10^{-13}$	$9,11 \times 10^{-7}$	$(3,0; 0,5)$ — correto
Newton + Armijo	1	$1,42 \times 10^1$	0	$(0; 1)$ — incorreto

O gradiente descendente converge corretamente ao mínimo global. Já o **método de Newton falha**: como a Hessiana em $(1, 1)$ é indefinida, a direção resultante é aproximadamente ortogonal ao gradiente ($g^T d \approx 0$), e a busca de Armijo nunca encontra decréscimo suficiente. O algoritmo estagna em $(0, 1)$, que não é o mínimo global, mas outro ponto crítico.




Figure 6: Curvas de nível: o GD converge ao ótimo, enquanto Newton fica preso em $(0, 1)$.

c)/d) Influência do ponto inicial

Em $x_0 = (3, 0,5)$, o próprio ponto já é o mínimo global, de modo que ambos os métodos convergem em 0 iterações. Para tornar a comparação mais reveladora, testou-se também um terceiro ponto, $x_0 = (1, 4)^T$: o gradiente descendente não converge dentro de 1000 iterações, e o método de Newton converge (em 11 iterações) para o mesmo ponto crítico incorreto $(0, 1)$. Esses resultados evidenciam a forte sensibilidade ao ponto inicial, típica de problemas não-convexos.




Figure 7: Trajetórias de GD e Newton para os três pontos iniciais testados.

e) Dificuldades do método do gradiente

As principais dificuldades observadas foram: (i) um vale curvo e não-quadrático, em que a direção de descida muda de orientação a cada iteração; (ii) instabilidade no tamanho do passo aceito por Armijo, que oscilou entre aproximadamente 0,03 e 0,5 ao longo da trajetória; (iii) presença de regiões com Hessiana indefinida no relevo geral da função; (iv) forte dependência do ponto inicial, como mostrado no item anterior; e (v) o fato de que o método de Newton, embora potencialmente mais rápido, pode convergir para pontos críticos incorretos quando a Hessiana não é definida positiva — tornando o gradiente descendente, apesar de mais lento, a opção mais robusta neste problema.

4 Problema 4: $f(x, y) = \sin(x + y) + (x - y)^2 - 1,5x + 2,5y + 1$

a) Gradiente e Hessiana

O gradiente é

$$\nabla f(x, y) = \begin{pmatrix} \cos(x + y) + 2(x - y) - 1,5 \\ \cos(x + y) - 2(x - y) + 2,5 \end{pmatrix}.$$

Os autovalores da Hessiana têm forma fechada: $\lambda_1 = 4$ (sempre positivo) e $\lambda_2 = -2\sin(x + y)$ (variável). Assim, H é definida positiva quando $\sin(x + y) < 0$, indefinida quando $\sin(x + y) > 0$, e **singular** quando $\sin(x + y) = 0$ — a convexidade local muda conforme a região do plano (x, y) , diferente dos Problemas 1 e 2.

b)/c) Testando os três pontos iniciais

A Tabela 5 apresenta os resultados para os três pontos pedidos: $(0, 0)^T$, $(2, -2)^T$ e $(-3, -3)^T$.

Table 5: Problema 4 — resultados para os três pontos iniciais.

x_0	Método	Iter.	f^*	Status	
$(0, 0)$	GD	+	30	-1,913	convergiu
	Armijo				
$(0, 0)$	Newton	+	0	1,000	Hessiana singular
	Armijo				
$(2, -2)$	GD	+	28	-1,913	convergiu
	Armijo				
$(2, -2)$	Newton	+	0	9,000	Hessiana singular
	Armijo				
$(-3, -3)$	GD	+	29	-5,055	convergiu
	Armijo				
$(-3, -3)$	Newton	+	1000	-1,721	travou (limite de iterações)
	Armijo				

Em $(0, 0)$ e $(2, -2)$, tem-se $\sin(x + y) = 0$, de modo que a Hessiana é singular e o método de Newton falha imediatamente. Em $(-3, -3)$, a Hessiana é indefinida mas não singular; ainda assim, a direção de Newton aponta para subida, e a busca de Armijo nunca aceita um passo — o método permanece parado no ponto inicial pelas 1000 iterações permitidas. O gradiente descendente, por outro lado, converge nos três casos, embora para **mínimos locais diferentes**, confirmando a não-convexidade da função.




Figure 8: Trajetórias do GD+Armijo para os três pontos iniciais testados.

d) A direção de Newton é sempre de descida?

Em $x_0 = (-3, -3)$, obteve-se $\nabla f^T d = 5,63 > 0$, ou seja, direção de **subida**. Para quantificar esse comportamento, realizou-se uma varredura sistemática em uma grade 80×80 no domínio $[-8, 6] \times [-8, 6]$, excluindo pontos com Hessiana singular ou gradiente nulo. Dos 6400 pontos válidos, 93,7% apresentaram direção de descida ($\nabla f^T d < 0$), enquanto 6,3% apresentaram direção de **subida** ($\nabla f^T d > 0$). Conclui-se experimentalmente que a direção de Newton não é sempre uma direção de descida nesta função — a garantia teórica só vale quando a Hessiana é definida positiva.




Figure 9: Mapa de $\nabla f^T d$: verde indica direção de descida, vermelho indica direção de subida.

e) Discussão dos resultados

O gradiente descendente, com $d = -\nabla f$, é sempre uma direção de descida por construção ($\nabla f^T d = -\|\nabla f\|^2 \leq 0$), independentemente da Hessiana — por isso se mostrou mais robusto neste problema. O método de Newton só garante descida quando a Hessiana é definida positiva; fora dessa condição, pode falhar por Hessiana singular, estagnar por seguir uma direção de subida, ou convergir para pontos críticos incorretos. Na prática, variantes regularizadas (Newton modificado, métodos quase-Newton como BFGS) são empregadas para mitigar essas limitações.

Conclusão Geral

O método de Newton converge muito mais rapidamente quando a Hessiana é definida positiva, resolvendo problemas quadráticos em uma única iteração e sendo completamente imune ao condicionamento nesses casos. Entretanto, é estruturalmente vulnerável em regiões não-convexas, podendo falhar, estagnar ou convergir para pontos críticos incorretos. O gradiente descendente, embora mais lento e sensível ao condicionamento da Hessiana, garante sempre uma direção de descida, sendo a opção mais robusta em paisagens não-convexas ou mal definidas.